```
feature_corr = train[top_corr_features].corr(numeric_only=True).abs()

high_corr_pairs = []

for i, col1 in enumerate(feature_corr.columns):
    for col2 in feature_corr.columns[i + 1:]:
        corr_value = feature_corr.loc[col1, col2]
        if corr_value >= 0.8:
            high_corr_pairs.append({
                "feature_1": col1,
                "feature_2": col2,
                "abs_corr": corr_value
            })

high_corr_df = pd.DataFrame(high_corr_pairs)

if len(high_corr_df) > 0:
    high_corr_df = high_corr_df.sort_values("abs_corr", ascending=False)

display(high_corr_df.head(30))
```

	feature_1	feature_2	abs_corr
8	동결 배아 사용 여부	신선 배아 사용 여부	0.996911
5	미세주입에서 생성된 배아 수	미세주입된 난자 수	0.939846
2	혼합된 난자 수	파트너 정자와 혼합된 난자 수	0.913231
0	총 생성 배아 수	혼합된 난자 수	0.891841
3	혼합된 난자 수	수집된 신선 난자 수	0.872449
7	배란 자극 여부	신선 배아 사용 여부	0.811952
6	배란 자극 여부	동결 배아 사용 여부	0.810742
1	총 생성 배아 수	파트너 정자와 혼합된 난자 수	0.810535
4	파트너 정자와 혼합된 난자 수	수집된 신선 난자 수	0.809544

01-8. 결과 해석

- `임신 성공 여부` 와 가장 상관관계가 높은 수치형 변수는 `이식된 배아 수`, `배아 이식 경과일`, `총 생성 배아 수`, `단일 배아 이식 여부`, `혼합된 난자 수` 였다.
- 상위 변수들이 대부분 난자·배아 생성·이식 과정과 관련되어 있어, 임신 성공 여부는 단순 인구통계 변수보다 실제 시술 진행 결과와 더 직접적으로 연결되어 있음을 확인할 수 있다.
- 다만 가장 높은 상관계수도 약 0.16 수준이므로, 단일 변수만으로는 임신 성공 여부를 강하게 설명하기 어렵다. 따라서 모델링 단계에서는 변수 간 조합, 구간화, 결측 flag, 비율 변수 등을 함께 활용할 필요가 있다.
- `임신 시도 또는 마지막 임신 경과 연수` 는 음의 상관관계를 보였으며, 기간이 길수록 임신 성공률이 낮아지는 방향성을 보인다.
- `동결 배아 사용 여부` 와 `신선 배아 사용 여부` 는 상관계수가 약 0.997로 매우 높아 사실상 중복 정보에 가깝다. 이후 Feature Importance 또는 OOF 성능 비교를 통해 하나만 남기거나 조합 변수로 재구성할 수 있다.
- `미세주입된 난자 수` 와 `미세주입에서 생성된 배아 수`, `혼합된 난자 수` 와 `파트너 정자와 혼합된 난자 수` 도 높은 상관관계를 보여 중복 또는 파생 비율 변수 후보로 판단된다.
- 초기 모델에서는 변수 제거를 바로 수행하지 않고, 이후 모델링 결과와 Feature Importance를 기준으로 noise pruning 여부를 결정한다.

01-9. EDA 종합 정리 및 전처리 방향 제시

EDA를 통해 확인한 핵심 내용과 이후 전처리 방향은 다음과 같다.

1. 데이터 구조

- train 데이터에는 target인 `임신 성공 여부` 가 포함되어 있고, test 데이터에는 target이 없다.
- train과 test의 컬럼 차이는 target 컬럼 하나뿐이며, 기본 데이터 구조는 정상적이다.
- 최종 목표는 test 데이터의 `임신 성공 여부` 확률을 예측하는 것이다.

2. 타깃 분포

- 임신 실패(0)는 약 74.2%, 임신 성공(1)은 약 25.8%로 나타났다.
- 성공 클래스가 상대적으로 적은 불균형 이진 분류 문제이다.
- 따라서 Accuracy보다 ROC-AUC를 핵심 평가 지표로 사용하고, LogLoss, Recall, F1-score를 보조 지표로 함께 확인한다.

3. 결측 패턴

- 일부 변수는 결측률이 90% 이상으로 매우 높게 나타났다.
- DI 시술에서는 배아·난자·이식 관련 변수의 결측률이 100%에 가깝게 나타났다.
- 이는 단순 누락이 아니라 시술 프로세스 차이에 따른 구조적 결측으로 해석할 수 있다.
- 따라서 결측값은 일괄 삭제하거나 평균값으로 대체하기보다, 결측 여부 자체를 feature로 활용할 필요가 있다.

4. 주요 범주형 변수

- `시술 유형` 에서는 IVF가 DI보다 성공률이 높게 나타났다.
- `시술 당시 나이` 는 성공률과 뚜렷한 관련이 있으며, 나이가 증가할수록 전반적으로 성공률이 낮아졌다.
- `특정 시술 유형` 에서는 BLASTOCYST가 포함된 유형의 성공률이 상대적으로 높았다.
- `배아 생성 주요 이유`, `난자 출처`, `정자 출처`, `신선/동결 배아 사용 여부` 도 성공률 차이를 보였다.
- 범주형 변수 간 조합이 의미를 가질 가능성이 있어, 이후 조합 변수를 생성한다.

5. 나이·난자·배아 구간 패턴

- 나이에서는 38세 전후로 성공률 하락 폭이 커지는 패턴이 확인되었다.
- 40세 이상, 43세 이상 구간에서도 추가적인 성공률 하락이 나타났다.
- 난자 수는 6개 이상 또는 11개 이상 구간에서 성공률이 높아지는 경향을 보였다.
- 총 생성 배아 수는 3개 이상부터 성공률이 상승하는 경향을 보였다.
- 이식된 배아 수는 단순히 많을수록 좋은 것이 아니라, 1-2개 구간에서 성공률이 높게 나타났다.
- 저장된 배아 수는 일정 수준 이후 성공률이 더 이상 증가하지 않는 패턴을 보였다.
- 따라서 수량형 변수는 원본값뿐 아니라 구간화 변수를 함께 활용한다.

6. 임상 지식 기반 결측 유추

- `해동된 배아 수 >= 1` 인 경우 FER 관련 시술 가능성이 있다.
- `미세주입된 난자 수 >= 1` 인 경우 ICSI 관련 시술 가능성이 있다.
- `배란 자극 여부 == 0` 인 경우 자연주기 또는 비자극 방식 가능성이 있다.
- 단, 이러한 유추는 원본 값을 직접 대체하기보다 flag 변수로 먼저 활용하는 것이 안전하다.

7. 이상치 후보

- IQR 기준 이상치 후보는 주로 난자 수, 배아 수, 혼합 난자 수 등 수량형 변수에서 나타났다.
- 최대값 51처럼 큰 값이 존재하지만, 의료 시술 과정에서 발생 가능한 실제 기록일 수 있다.
- 따라서 이상치 후보를 일괄 삭제하지 않고, 구간화 또는 clipping 여부를 모델 성능 기준으로 판단한다.

8. 수치형 변수 간 상관관계

- `이식된 배아 수`, `배아 이식 경과일`, `총 생성 배아 수`, `단일 배아 이식 여부`, `혼합된 난자 수` 가 target과 상대적으로 높은 상관관계를 보였다.
- 다만 가장 높은 상관계수도 약 0.16 수준으로, 단일 변수만으로는 임신 성공 여부를 강하게 설명하기 어렵다.
- `동결 배아 사용 여부` 와 `신선 배아 사용 여부` 처럼 서로 매우 높은 상관관계를 가진 변수들이 존재한다.
- 이러한 변수들은 이후 Feature Importance와 OOF 성능을 기준으로 noise pruning 여부를 검토한다.

9. 전처리 및 Feature Engineering 방향

- train/test를 동일한 기준으로 처리하기 위해 두 데이터를 합친 뒤 feature를 생성한다.
- target과 ID는 별도로 보존한다.
- 구조적 결측 가능성이 있는 변수는 missing flag를 생성한다.
- 나이는 순서형 변수로 변환하고, 38세 이상·40세 이상·43세 이상 flag를 생성한다.
- 난자 수, 배아 수, 이식 배아 수는 성공률 패턴을 반영하여 구간화한다.
- FER, ICSI, 자연주기 가능성을 나타내는 임상 지식 기반 flag를 생성한다.
- `나이 x 난자 출처`, `시술 유형 x 특정 시술 유형`, `배아 생성 주요 이유 x 특정 시술 유형` 등 조합 변수를 생성한다.
- 초기에는 후보 변수를 넓게 사용하고, 모델링 이후 중요도가 낮은 변수는 성능 검증을 통해 제거한다.

10. 모델링 방향

- 범주형 변수가 많고 결측 자체가 의미를 가질 수 있으므로 CatBoost를 주요 후보 모델로 사용한다.
- LightGBM, XGBoost도 함께 비교하여 트리 기반 모델 간 성능 차이를 확인한다.
- K Fold OOF 검증을 통해 모델의 일반화 성능을 안정적으로 평가한다.
- 최종 단계에서는 단일 모델보다 여러 모델의 예측값을 조합하는 ensemble을 검토한다.

02. 데이터 전처리 및 Feature Engineering

EDA 결과를 바탕으로 모델 입력에 사용할 변수를 생성한다.
본 프로젝트에서는 결측값을 단순히 삭제하거나 평균값으로 대체하지 않고, 시술 프로세스의 차이를 반영하는 신호로 활용한다.

기존 기본 전처리에서 달라지는 점은 다음과 같다.

1. 결측값을 일괄 대체하지 않는다.

- DI 시술처럼 특정 과정이 존재하지 않아 발생하는 구조적 결측이 있으므로, 결측 여부를 별도 flag로 생성한다.

2. train/test를 합쳐 동일한 기준으로 feature를 생성한다.

- train과 test에 서로 다른 기준이 적용되지 않도록, target을 분리한 뒤 전체 데이터를 합쳐 전처리한다.

3. 수량형 변수는 원본값과 구간화 변수를 함께 사용한다.

- 난자 수, 배아 수, 이식 배아 수는 단순 선형 관계가 아니라 구간별 성공률 차이가 나타났기 때문이다.

4. 임상 지식 기반 유추 feature를 생성한다.

- 해동된 배아 수, 미세주입된 난자 수, 배란 자극 여부 등을 활용해 FER, ICSI, 자연주기 가능성을 flag로 만든다.

5. 모델별 전처리 전략을 분리한다.

- CatBoost는 범주형 변수와 결측값 처리에 강점이 있으므로 주요 모델로 사용한다.
- LightGBM, XGBoost, 선형 모델은 필요에 따라 인코딩·결측 대체 방식을 별도로 적용한다.

02-1. Target 분리 및 train/test 통합

전처리 과정에서 target 정보가 test 데이터에 섞이지 않도록 `임신 성공 여부` 를 먼저 분리한다.
이후 train과 test를 합쳐 동일한 기준으로 파생변수를 생성한다.

기본 전처리 방향은 다음과 같다.

- 원본 데이터는 보존하고, 전처리용 복사본을 생성한다.
- ID 컬럼은 모델 학습에는 사용하지 않고 제출 파일 생성 시에만 사용한다.
- target 컬럼인 `임신 성공 여부` 는 train 데이터에서만 분리한다.
- 범주형 결측은 `Unknown` 또는 `missing` 범주로 처리한다.
- 수치형 결측은 모델에 따라 NaN 유지 또는 중앙값 대체를 적용한다.
- 구조적 결측은 별도의 missing flag 변수로 생성한다.
- EDA에서 확인한 나이, 난자, 배아 관련 구간화 변수를 생성한다.

In [23]:
```
# 원본 데이터 보존 및 전처리용 데이터 생성
train_raw = train.copy()
test_raw = test.copy()

y = train_raw[TARGET].astype(int)

train_base = train_raw.drop(columns=[TARGET]).copy()
test_base = test_raw.copy()

print("train_raw:", train_raw.shape)
print("test_raw:", test_raw.shape)
print("train_base:", train_base.shape)
print("test_base:", test_base.shape)
print("y:", y.shape)
```

```
train_raw: (256351, 69)
test_raw: (90067, 68)
train_base: (256351, 68)
test_base: (90067, 68)
y: (256351,)
```

In [24]:
```
# train/test를 함께 결합하여 동일한 전처리 적용
all_data = pd.concat(
    [train_base, test_base],
    axis=0,
    ignore_index=True
)

print("all_data:", all_data.shape)
print("train rows:", len(train_base))
print("test rows:", len(test_base))
```

```
all_data: (346418, 68)
train rows: 256351
test rows: 90067
```

02-1. 처리 방식 설명

전처리를 시작하기 전에 원본 train/test 데이터를 복사하여 보존하였다.
이후 모든 전처리와 파생변수 생성은 복사본을 기준으로 수행한다.

train 데이터에서는 target 컬럼인 `임신 성공 여부` 를 분리하여 `y` 로 저장하였다.
모델 학습에는 target을 제외한 feature만 사용하며, ID 컬럼은 최종 제출 파일 생성 시에만 활용한다.

또한 train과 test에 동일한 전처리 규칙을 적용하기 위해 두 데이터를 `all_data` 로 결합하였다.
이 방식은 train/test 간 컬럼 불일치나 파생변수 생성 방식 차이를 방지하는 데 도움이 된다.

단, target 정보를 사용하는 Target Encoding과 같은 전처리는 반드시 train 내부 fold에서만 계산해야 하므로, 이후 별도 단계에서 처리한다.

02-2. 임상 지식 기반 결측 유추 Feature 생성

EDA에서 확인한 내용을 바탕으로, 시술 프로세스상 의미가 있는 조건을 flag 변수로 생성한다.

이 단계에서는 원본 결측값이나 범주값을 직접 대체하지 않고, 도메인 지식 기반 유추 결과를 별도의 feature로 추가한다.
이는 잘못된 대체로 인한 정보 왜곡을 줄이면서도, 모델이 시술 프로세스 신호를 학습할 수 있도록 하기 위함이다.

In [26]:
```
# 임상 지식 기반 유추 flag 생성
def to_numeric_safe(df, col):
    if col in df.columns:
        return pd.to_numeric(df[col], errors="coerce")
    return pd.Series(np.nan, index=df.index)


all_data["fer_inferred_flag"] = (
    to_numeric_safe(all_data, "해동된 배아 수").fillna(0) >= 1
).astype(int)

all_data["icsi_inferred_flag"] = (
    to_numeric_safe(all_data, "미세주입된 난자 수").fillna(0) >= 1
).astype(int)

all_data["natural_cycle_inferred_flag"] = (
    to_numeric_safe(all_data, "배란 자극 여부").fillna(-1) == 0
).astype(int)

all_data["unknown_proc_with_thawed_embryo_flag"] = (
    all_data["특정 시술 유형"].astype("string").fillna("Unknown").isin(["Unknown", "알 수 없음"])
    & (to_numeric_safe(all_data, "해동된 배아 수").fillna(0) >= 1)
).astype(int)

all_data["unknown_proc_with_icsi_oocyte_flag"] = (
    all_data["특정 시술 유형"].astype("string").fillna("Unknown").isin(["Unknown", "알 수 없음"])
    & (to_numeric_safe(all_data, "미세주입된 난자 수").fillna(0) >= 1)
).astype(int)

inferred_cols = [
    "fer_inferred_flag",
    "icsi_inferred_flag",
    "natural_cycle_inferred_flag",
    "unknown_proc_with_thawed_embryo_flag",
    "unknown_proc_with_icsi_oocyte_flag",
]

display(all_data[inferred_cols].sum().to_frame("count"))
```

	count
fer_inferred_flag	54345
icsi_inferred_flag	165653
natural_cycle_inferred_flag	78942
unknown_proc_with_thawed_embryo_flag	36131
unknown_proc_with_icsi_oocyte_flag	109

In [27]:
```
# train 영역 기준 유추 flag별 임신 성공률 확인
train_inferred = all_data.iloc[:len(train_base)].copy()
train_inferred[TARGET] = y.values

for col in inferred_cols:
    result = (
        train_inferred.groupby(col)[TARGET]
        .agg(["count", "mean"])
        .rename(columns={"mean": "success_rate"})
        .assign(success_rate_percent=lambda x: x["success_rate"] * 100)
    )

    print("\n" + "=" * 80)
    print(col)
    display(result)
```

```
================================================================================
fer_inferred_flag
```

fer_inferred_flag	count	success_rate	success_rate_percent
0	215966	0.263930	26.393043
1	40385	0.228501	22.850068

```
================================================================================
icsi_inferred_flag
```

icsi_inferred_flag	count	success_rate	success_rate_percent
0	133960	0.245021	24.502090
1	122391	0.272937	27.293674

```
================================================================================
natural_cycle_inferred_flag
```

natural_cycle_inferred_flag	count	success_rate	success_rate_percent
0	197720	0.266265	26.626543
1	58631	0.231652	23.165220

```
================================================================================
unknown_proc_with_thawed_embryo_flag
```

unknown_proc_with_thawed_embryo_flag	count	success_rate	success_rate_percent
0	229427	0.260832	26.083242
1	26924	0.237186	23.718615

```
================================================================================
unknown_proc_with_icsi_oocyte_flag
```

unknown_proc_with_icsi_oocyte_flag	count	success_rate	success_rate_percent
0	256277	0.258373	25.837278
1	74	0.175676	17.567568

02-2. 결과 해석

임상 지식 기반 유추 flag 변수를 생성하고, train 데이터 기준으로 각 flag별 임신 성공률을 확인하였다.

먼저 `fer_inferred_flag` 는 전체 all_data 기준 54,345건 생성되었으며, train 기준으로는 40,385건이 해당된다.
train 데이터에서 `fer_inferred_flag=1` 인 그룹의 임신 성공률은 약 22.9%로, flag가 0인 그룹의 약 26.4%보다 낮게 나타났다.
이는 해동된 배아가 존재하는 FER 관련 주기가 신선 배아 중심 주기와 다른 성공률 패턴을 가질 수 있음을 의미한다.

`icsi_inferred_flag` 는 전체 all_data 기준 165,653건으로 가장 많이 생성되었으며, train 기준으로는 122,391건이 해당된다.
`icsi_inferred_flag=1` 그룹의 성공률은 약 27.3%로, flag가 0인 그룹의 약 24.5%보다 높게 나타났다.
이는 미세주입 과정이 수행된 경우가 임신 성공 여부와 관련된 유의미한 신호일 수 있음을 보여준다.

`natural_cycle_inferred_flag` 는 전체 all_data 기준 78,942건 생성되었으며, train 기준으로는 58,631건이 해당된다.
해당 flag가 1인 그룹의 성공률은 약 23.2%로, flag가 0인 그룹의 약 26.6%보다 낮게 나타났다.
이는 배란 자극이 없는 자연주기 또는 비자극 방식이 별도의 시술 특성을 가지며, 모델이 구분해야 할 정보일 수 있음을 시사한다.

`unknown_proc_with_thawed_embryo_flag` 는 train 기준 26,924건으로 표본 수가 충분하며, 성공률은 약 23.7%로 나타났다.
이는 특정 시술 유형이 Unknown으로 기록되었더라도 해동된 배아 수가 존재하는 경우, 별도의 FER 관련 신호로 활용할 수 있음을 의미한다.

반면 `unknown_proc_with_icsi_oocyte_flag` 는 train 기준 74건으로 표본 수가 매우 작다.
성공률은 약 17.6%로 낮게 나타났지만, 표본 수가 적기 때문에 안정적인 일반화 신호로 보기에는 한계가 있다.
따라서 이 변수는 모델에 넣더라도 중요도가 낮을 수 있으며, 추후 Feature Importance를 통해 제거 여부를 검토한다.

종합하면, 임상 지식 기반 유추 flag 중 우선적으로 활용할 후보는 다음과 같다.

- `fer_inferred_flag`
- `icsi_inferred_flag`
- `natural_cycle_inferred_flag`
- `unknown_proc_with_thawed_embryo_flag`

이 변수들은 원본 값을 직접 대체하지 않고, 시술 프로세스의 간접 신호를 모델이 학습할 수 있도록 추가한 feature이다.

02-3. 구조적 결측 Flag 생성

EDA에서 DI와 IVF는 시술 프로세스가 다르며, 특히 DI에서는 배아·난자·이식 관련 변수가 구조적으로 결측되는 패턴을 확인하였다.

따라서 결측값을 단순히 대체하기 전에, 결측 여부 자체를 feature로 생성한다.
이는 모델이 "값이 없음(NaN)"을 단순 누락이 아니라 "해당 시술 과정이 수행되지 않았을 가능성"으로 학습할 수 있도록 하기 위함이다.

In [28]:
```
# 배아·난자·이식 관련 구조적 결측 flag 생성
process_cols = [
    "총 생성 배아 수",
    "미세주입된 난자 수",
    "미세주입에서 생성된 배아 수",
    "이식된 배아 수",
    "미세주입 배아 이식 수",
    "저장된 배아 수",
    "미세주입 후 저장된 배아 수",
    "해동된 배아 수",
    "해동 난자 수",
    "수집된 신선 난자 수",
    "저장된 신선 난자 수",
    "혼합된 난자 수",
    "파트너 정자와 혼합된 난자 수",
    "기증자 정자와 혼합된 난자 수",
    "난자 채취 경과일",
    "난자 해동 경과일",
    "난자 혼합 경과일",
    "배아 이식 경과일",
    "배아 해동 경과일",
]

process_cols = [col for col in process_cols if col in all_data.columns]

for col in process_cols:
    all_data[f"{col}_missing_flag"] = all_data[col].isna().astype(int)

all_data["process_missing_count"] = all_data[process_cols].isna().sum(axis=1)
all_data["process_missing_rate"] = all_data[process_cols].isna().mean(axis=1)

print("구조적 결측 대상 변수 수:", len(process_cols))
print("생성된 missing flag 수:", len(process_cols))
display(all_data[["process_missing_count", "process_missing_rate"]].describe())
```

```
구조적 결측 대상 변수 수: 19
생성된 missing flag 수: 19
```

	process_missing_count	process_missing_rate
count	346418.000000	346418.000000
mean	2.781870	0.146414
std	2.629279	0.138383
min	0.000000	0.000000
25%	2.000000	0.105263
50%	2.000000	0.105263
75%	3.000000	0.157895
max	19.000000	1.000000

In [29]:
```
# train 영역 기준 구조적 결측 개수별 성공률 확인
train_missing = all_data.iloc[:len(train_base)].copy()
train_missing[TARGET] = y.values

missing_count_success = (
    train_missing.groupby("process_missing_count")[TARGET]
    .agg(["count", "mean"])
    .rename(columns={"mean": "success_rate"})
    .assign(success_rate_percent=lambda x: x["success_rate"] * 100)
    .reset_index()
)

display(missing_count_success.head(30))

plt.figure(figsize=(10, 4))
plot_missing = missing_count_success[missing_count_success["count"] >= 100].copy()

ax = sns.barplot(
    data=plot_missing,
    x="process_missing_count",
    y="success_rate_percent",
    color=main_color
)

ax.set_title("구조적 결측 개수별 임신 성공률")
ax.set_xlabel("배아·난자·이식 관련 결측 개수")
ax.set_ylabel("임신 성공률(%)")

plt.tight_layout()
plt.show()
```

	process_missing_count	count	success_rate	success_rate_percent
0	1	469	0.208955	20.895522
1	2	166644	0.314611	31.461079
2	3	71314	0.178212	17.821185
3	4	11633	0.015645	1.564515
4	19	6291	0.128914	12.891432

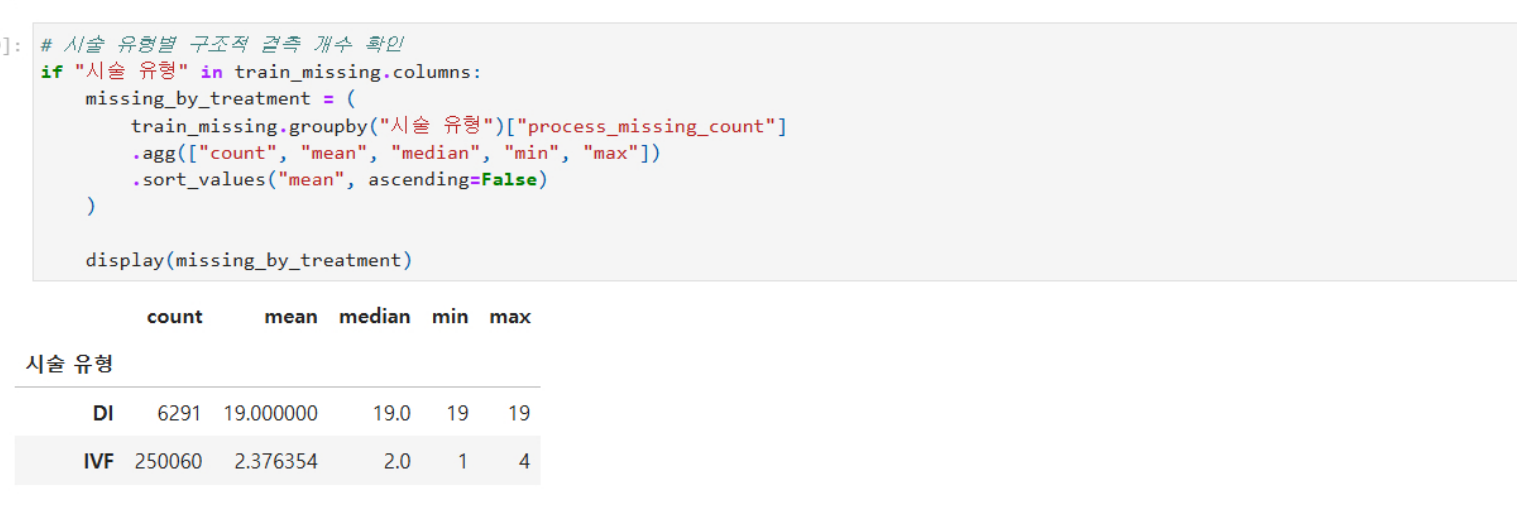

In [30]:
```
# 시술 유형별 구조적 결측 개수 확인
if "시술 유형" in train_missing.columns:
    missing_by_treatment = (
        train_missing.groupby("시술 유형")["process_missing_count"]
        .agg(["count", "mean", "median", "min", "max"])
        .sort_values("mean", ascending=False)
    )

    display(missing_by_treatment)
```

시술 유형	count	mean	median	min	max
DI	6291	19.000000	19.0	19	19
IVF	250060	2.376354	2.0	1	4

02-3. 결과 해석 및 결론

배아·난자·이식 관련 변수 19개를 구조적 결측 후보 변수로 정의하고, 각 변수에 대해 missing flag를 생성하였다.
또한 각 행에서 해당 변수들이 몇 개 결측인지 나타내는 `process_missing_count` 와 결측 비율인 `process_missing_rate` 를 생성하였다.

전체 all_data 기준 `process_missing_count` 의 평균은 약 2.78개이며, 중앙값은 2개로 나타났다.
즉, 대부분의 행은 배아·난자·이식 관련 변수 중 일부만 결측을 가지지만, 최대 19개까지 결측이 발생하는 행도 존재한다.

train 데이터 기준으로 `process_missing_count` 별 성공률을 확인한 결과, 결측 개수에 따라 성공률이 크게 달라졌다.
결측 개수가 2개인 그룹은 약 31.5%의 성공률을 보인 반면, 결측 개수가 3개인 그룹은 약 17.8%, 4개인 그룹은 약 1.6%로 크게 낮아졌다.
따라서 결측 개수 자체가 임신 성공 여부와 관련된 중요한 신호일 가능성이 있다.

특히 `process_missing_count` 가 19개인 그룹은 6,291건이며, 성공률은 약 12.9%로 나타났다.
이 6,291건은 시술 유형이 DI인 행과 정확히 일치한다.

시술 유형별로 확인한 결과, DI는 `process_missing_count` 의 평균, 중앙값, 최소값, 최대값이 모두 19로 나타났다.
즉, DI 시술에서는 배아·난자·이식 관련 19개 변수가 모두 결측이며, 이는 단순 누락이 아니라 DI 시술 프로세스상 해당 과정이 존재하지 않기 때문에 발생한 구조적 결측으로 해석할 수 있다.

반면 IVF는 `process_missing_count` 가 평균 약 2.38개, 중앙값 2개이며, 최소 1개에서 최대 4개까지 분포한다.
이는 IVF에서도 일부 경과일 또는 해동 관련 변수의 결측이 존재하지만, DI처럼 모든 배아·난자·이식 변수가 결측되는 구조는 아님을 보여준다.

종합하면, `process_missing_count`, `process_missing_rate`, 그리고 개별 missing flag 변수들은 시술 유형과 시술 진행 과정을 반영하는 중요한 파생변수로 판단된다.

이후 모델링에서는 다음 변수를 활용한다.

- 개별 배아·난자·이식 관련 missing flag
- `process_missing_count`
- `process_missing_rate`
- `process_missing_count == 19` 여부

이 변수들은 모델이 단순 수치값뿐 아니라, 시술 프로세스의 존재 여부와 구조적 결측 패턴을 함께 학습하도록 돕는다.

02-4. 구간화 변수 생성

EDA에서 나이, 난자 수, 배아 수는 임신 성공률과 관련된 구간 패턴을 보였다.

따라서 원본 수치 또는 범주형 변수를 그대로 사용하는 것과 함께, 임상적 의미를 반영한 구간화 변수를 추가로 생성한다.

구간화 변수는 모델이 특정 임계점이나 plateau 패턴을 더 쉽게 학습하도록 돕는다.

In [32]:
```
# 나이, 난자 수, 배아 수 구간화 함수 정의
age_ord_map = {
    "만18-34세": 0,
    "만35-37세": 1,
    "만38-39세": 2,
    "만40-42세": 3,
    "만43-44세": 4,
    "만45-50세": 5,
    "알 수 없음": np.nan,
}

def make_oocyte_bin(s):
    return pd.cut(
        s,
        bins=[-0.1, 0, 5, 10, np.inf],
        labels=["0개", "1-5개", "6-10개", "11개 이상"],
        include_lowest=True
    )

def make_embryo_bin(s):
    return pd.cut(
        s,
        bins=[-0.1, 0, 2, 5, np.inf],
        labels=["0개", "1-2개", "3-5개", "6개 이상"],
        include_lowest=True
    )

def make_transfer_embryo_bin(s):
    return pd.cut(
        s,
        bins=[-0.1, 0, 2, np.inf],
        labels=["0개", "1-2개", "3개 이상"],
        include_lowest=True
    )
```

In [33]:
```
# 나이 관련 구간화 및 threshold 변수 생성
all_data["age_ord"] = all_data["시술 당시 나이"].map(age_ord_map)
all_data["age_38plus_flag"] = (all_data["age_ord"] >= 2).astype(int)
all_data["age_40plus_flag"] = (all_data["age_ord"] >= 3).astype(int)
all_data["age_43plus_flag"] = (all_data["age_ord"] >= 4).astype(int)
all_data["age_unknown_flag"] = all_data["age_ord"].isna().astype(int)

age_feature_cols = [
    "age_ord",
    "age_38plus_flag",
    "age_40plus_flag",
    "age_43plus_flag",
    "age_unknown_flag",
]

display(all_data[age_feature_cols].head())
display(all_data[age_feature_cols].sum(numeric_only=True).to_frame("sum"))
```

	age_ord	age_38plus_flag	age_40plus_flag	age_43plus_flag	age_unknown_flag
0	0.0	0	0	0	0
1	5.0	1	1	1	0
2	0.0	0	0	0	0
3	1.0	0	0	0	0
4	0.0	0	0	0	0

	sum
age_ord	448304.0
age_38plus_flag	129328.0
age_40plus_flag	76470.0

age_43plus_flag	25856.0
age_unknown_flag	445.0

In [34]:
```python
# 난자 수 구간화 변수 생성
oocyte_bin_cols = [
    "수집된 신선 난자 수",
    "혼합된 난자 수",
    "해동 난자 수",
]

for col in oocyte_bin_cols:
    if col in all_data.columns:
        all_data[f"{col}_bin"] = make_oocyte_bin(
            pd.to_numeric(all_data[col], errors="coerce")
        ).astype("string").fillna("missing")

created_oocyte_bin_features = [f"{col}_bin" for col in oocyte_bin_cols if f"{col}_bin" in all_data.columns]

for col in created_oocyte_bin_features:
    print("\n" + "=" * 80)
    print(col)
    display(all_data[col].value_counts(dropna=False).to_frame("count"))
```

```
================================================================================
수집된 신선 난자 수_bin
```

수집된 신선 난자 수_bin	count
11개 이상	122273
6-10개	87678
0개	72525
1-5개	55475
missing	8467

```
================================================================================
혼합된 난자 수_bin
```

혼합된 난자 수_bin	count
6-10개	101121
11개 이상	98736
1-5개	75331
0개	62763
missing	8467

```
================================================================================
해동 난자 수_bin
```

해동 난자 수_bin	count
0개	336012
missing	8467
6-10개	981
1-5개	514
11개 이상	444

In [35]:
```python
# 배아 수 구간화 변수 생성
embryo_bin_cols = [
    "총 생성 배아 수",
    "저장된 배아 수",
]

for col in embryo_bin_cols:
    if col in all_data.columns:
        all_data[f"{col}_bin"] = make_embryo_bin(
            pd.to_numeric(all_data[col], errors="coerce")
        ).astype("string").fillna("missing")

if "이식된 배아 수" in all_data.columns:
    all_data["이식된 배아 수_bin"] = make_transfer_embryo_bin(
        pd.to_numeric(all_data["이식된 배아 수"], errors="coerce")
    ).astype("string").fillna("missing")

created_embryo_bin_features = [
    "총 생성 배아 수_bin",
    "저장된 배아 수_bin",
    "이식된 배아 수_bin",
]

created_embryo_bin_features = [
    col for col in created_embryo_bin_features if col in all_data.columns
]

for col in created_embryo_bin_features:
    print("\n" + "=" * 80)
    print(col)
    display(all_data[col].value_counts(dropna=False).to_frame("count"))
```

```
================================================================================
총 생성 배아 수_bin
```

총 생성 배아 수_bin	count
6개 이상	134143
3-5개	85394
0개	71823
1-2개	46591
missing	8467

```
================================================================================
저장된 배아 수_bin
```

저장된 배아 수_bin	count
0개	225572
1-2개	54444
3-5개	38794
6개 이상	19141
missing	8467

```
================================================================================
이식된 배아 수_bin
```

이식된 배아 수_bin	count
1-2개	276587
0개	49349
3개 이상	12015
missing	8467

In [36]:
```python
# train 영역 기준 생성된 구간화 변수별 성공률 확인
train_bins = all_data.iloc[:len(train_base)].copy()
train_bins[TARGET] = y.values

bin_feature_cols = (
    age_feature_cols
    + created_oocyte_bin_features
    + created_embryo_bin_features
)

for col in bin_feature_cols:
    result = (
        train_bins.groupby(col, dropna=False)[TARGET]
        .agg(["count", "mean"])
        .rename(columns={"mean": "success_rate"})
        .assign(success_rate_percent=lambda x: x["success_rate"] * 100)
        .sort_values("success_rate_percent", ascending=False)
    )

    print("\n" + "=" * 80)
    print(col)
    display(result)
```

```
================================================================================
age_ord
```

age_ord	count	success_rate	success_rate_percent
0.0	102476	0.322622	32.262188
1.0	57780	0.278401	27.840083
2.0	39247	0.217138	21.713762
5.0	6918	0.167679	16.767852
3.0	37348	0.159393	15.939274
4.0	12253	0.118012	11.801192
NaN	329	0.000000	0.000000

```
================================================================================
age_38plus_flag
```

age_38plus_flag	count	success_rate	success_rate_percent
0	160585	0.306050	30.604976
1	95766	0.178362	17.836184

```
================================================================================
age_40plus_flag
```

age_40plus_flag	count	success_rate	success_rate_percent
0	199832	0.288587	28.858741
1	56519	0.151436	15.143580

```
================================================================================
age_43plus_flag
```

age_43plus_flag	count	success_rate	success_rate_percent
0	237180	0.268244	26.824353
1	19171	0.135934	13.593448

```
================================================================================
age_unknown_flag
```

age_unknown_flag	count	success_rate	success_rate_percent
0	256022	0.258681	25.868089
1	329	0.000000	0.000000

```
================================================================================
수집된 신선 난자 수_bin
```

수집된 신선 난자 수_bin	count	success_rate	success_rate_percent
11개 이상	90522	0.320828	32.082809
6-10개	64733	0.267777	26.777687
0개	53845	0.240487	24.048658
1-5개	40960	0.148730	14.873047
missing	6291	0.128914	12.891432

```
================================================================================
혼합된 난자 수_bin
```

혼합된 난자 수_bin	count	success_rate	success_rate_percent
11개 이상	73164	0.332554	33.255426
6-10개	74683	0.296118	29.611826
0개	46650	0.196227	19.622722
1-5개	55563	0.176682	17.668232
missing	6291	0.128914	12.891432

```
================================================================================
해동 난자 수_bin
```

해동 난자 수_bin	count	success_rate	success_rate_percent
11개 이상	323	0.291022	29.102167
0개	248615	0.261835	26.183456
6-10개	729	0.252401	25.240055
missing	6291	0.128914	12.891432
1-5개	393	0.109415	10.941476

```
================================================================================
총 생성 배아 수_bin
```

총 생성 배아 수_bin	count	success_rate	success_rate_percent
6개 이상	99324	0.342848	34.284765
3-5개	62974	0.274637	27.463715
0개	53349	0.171868	17.186826
1-2개	34413	0.142388	14.238805
missing	6291	0.128914	12.891432

```
================================================================================
저장된 배아 수_bin
```

저장된 배아 수_bin	count	success_rate	success_rate_percent
3-5개	28731	0.362431	36.243082
1-2개	40245	0.357759	35.775873
6개 이상	14218	0.248980	24.898017
0개	166866	0.222130	22.213033
missing	6291	0.128914	12.891432

```
================================================================================
이식된 배아 수_bin
```

이식된 배아 수_bin	count	success_rate	success_rate_percent
1-2개	204636	0.312218	31.221779
3개 이상	8880	0.168468	16.846847
missing	6291	0.128914	12.891432
0개	36544	0.000821	0.082093

02-4. 결과 해석

EDA에서 확인한 나이, 난자 수, 배아 수의 구간 패턴을 바탕으로 구간화 파생변수를 생성하고, train 기준 성공률을 확인하였다.

먼저 나이 관련 변수에서는 성공률 차이가 매우 뚜렷하게 나타났다.
`age_38plus_flag` 기준으로 38세 미만 그룹의 성공률은 약 30.6%, 38세 이상 그룹은 약 17.8%로 크게 낮아졌다.
`age_40plus_flag` 에서도 40세 미만은 약 28.9%, 40세 이상은 약 15.1%로 차이가 나타났으며, `age_43plus_flag` 역시 43세 이상에서 성공률이 약 13.6%로 낮게 나타났다.
따라서 38세, 40세, 43세 기준 threshold 변수는 임신 성공률 하락 구간을 반영하는 중요한 feature로 활용할 수 있다.

난자 수 관련 변수에서는 `수집된 신선 난자 수` 와 `혼합된 난자 수` 모두 6개 이상 구간부터 성공률이 높아지는 패턴이 확인되었다.
특히 `수집된 신선 난자 수` 는 11개 이상 구간에서 약 32.1%, `혼합된 난자 수` 는 11개 이상 구간에서 약 33.3%로 가장 높은 성공률을 보였다.
반면 1-5개 구간은 0개 구간보다도 낮은 성공률을 보여, 난자 수가 단순히 0보다 많다고 해서 성공률이 바로 증가하는 것은 아님을 확인할 수 있다.

`해동 난자 수` 는 대부분이 0개 구간에 몰려 있으며, 1개 이상 구간의 표본 수가 상대적으로 작다.
따라서 이 변수의 구간별 성공률은 해석에 주의가 필요하며, 단독 구간화 변수보다는 해동 여부 또는 다른 변수와의 조합으로 활용하는 것이 적절할 수 있다.

배아 수 관련 변수에서는 `총 생성 배아 수` 가 3개 이상부터 성공률이 상승하고, 6개 이상 구간에서 약 34.3%로 가장 높게 나타났다.
이는 생성된 배아 수가 일정 수준 이상 확보될 때 임신 성공 가능성이 높아질 수 있음을 의미한다.

`저장된 배아 수` 는 1-2개와 3-5개 구간에서 성공률이 약 35~36%로 높게 나타났고, 6개 이상에서는 약 24.9%로 낮아졌다.
이는 저장 배아 수가 많을수록 무조건 성공률이 높아지는 것이 아니라, 일정 수준 이후에는 효과가 둔화되거나 다른 조건과 함께 해석해야 함을 시사한다.

`이식된 배아 수` 에서는 1-2개 구간의 성공률이 약 31.2%로 가장 높게 나타났다.
반면 0개 구간은 성공률이 약 0.08%로 거의 없고, 3개 이상 구간은 약 16.8%로 낮아졌다.
따라서 이식된 배아 수는 단순히 많을수록 좋은 변수가 아니라, 적정 이식 수가 중요한 변수로 해석된다.

또한 각 구간화 변수에서 `missing` 그룹은 약 12.9%의 성공률을 보이며, 이는 DI 시술의 구조적 결측 패턴과 연결될 가능성이 높다.
따라서 missing을 단순 대체하지 않고 별도 범주로 유지하는 것이 적절하다.

종합하면, 다음 구간화 변수들은 모델 입력 feature로 활용할 가치가 있다.

- `age_ord`
- `age_38plus_flag`
- `age_40plus_flag`
- `age_43plus_flag`
- `수집된 신선 난자 수_bin`
- `혼합된 난자 수_bin`
- `총 생성 배아 수_bin`
- `저장된 배아 수_bin`
- `이식된 배아 수_bin`

이후 모델링 단계에서는 원본 수치형 변수와 구간화 변수를 함께 사용한 뒤, Feature Importance와 OOF ROC-AUC 등 평가지표를 기준으로 실제 기여도를 판단한다.

02-5. 조합 변수 및 비율 변수 생성

EDA 결과, 단일 변수뿐 아니라 변수 간 조합이 임신 성공률과 관련될 가능성이 확인되었다.

특히 나이와 난자 출처, 시술 유형과 특정 시술 유형, 배아 생성 수와 이식 수의 관계는 단독 변수보다 조합으로 해석할 때 더 의미가 클 수 있다.

따라서 주요 조합 변수와 비율 변수를 생성하여 모델이 변수 간 상호작용을 학습할 수 있도록 한다.

In [37]:
```python
# 안전한 비율 계산 함수
def safe_ratio(numerator, denominator):
    numerator = pd.to_numeric(numerator, errors="coerce")
    denominator = pd.to_numeric(denominator, errors="coerce").replace(0, np.nan)
    return (numerator / denominator).replace([np.inf, -np.inf], np.nan)
```

In [38]:
```python
# 주요 조합 변수 생성
all_data["age_x_egg_source"] = (
    all_data["시술 당시 나이"].astype("string").fillna("missing")
    + "__"
    + all_data["난자 출처"].astype("string").fillna("missing")
)

all_data["treatment_x_specific_proc"] = (
    all_data["시술 유형"].astype("string").fillna("missing")
    + "__"
    + all_data["특정 시술 유형"].astype("string").fillna("missing")
)

all_data["age_x_specific_proc"] = (
    all_data["시술 당시 나이"].astype("string").fillna("missing")
    + "__"
    + all_data["특정 시술 유형"].astype("string").fillna("missing")
)

all_data["reason_x_specific_proc"] = (
    all_data["배아 생성 주요 이유"].astype("string").fillna("missing")
    + "__"
    + all_data["특정 시술 유형"].astype("string").fillna("missing")
)

combo_cols = [
    "age_x_egg_source",
    "treatment_x_specific_proc",
    "age_x_specific_proc",
    "reason_x_specific_proc",
]

for col in combo_cols:
    print("\n" + "=" * 80)
    print(col)
    display(all_data[col].value_counts(dropna=False).head(15).to_frame("count"))
```

```
================================================================================
age_x_egg_source
```

age_x_egg_source	count
만18-34세__본인 제공	132004
만35-37세__본인 제공	73479
만38-39세__본인 제공	49222
만40-42세__본인 제공	44893
만43-44세__본인 제공	12620
만45-50세__기증 제공	4959
만40-42세__기증 제공	4330
만45-50세__본인 제공	4025
만18-34세__기증 제공	3899
만43-44세__기증 제공	3337
만18-34세__알 수 없음	2751
만35-37세__기증 제공	2538
만38-39세__기증 제공	2200
만35-37세__알 수 없음	1974
만38-39세__알 수 없음	1436

```
================================================================================
treatment_x_specific_proc
```

treatment_x_specific_proc	count
IVF__ICSI	165605
IVF__IVF	124105
IVF__Unknown	36155
DI__IUI	8212
IVF__ICSI:ICSI	3111
IVF__ICSI / BLASTOCYST	2193
IVF__IVF / BLASTOCYST	1637
IVF__IVF:IVF	1552
IVF__ICSI:IVF	1171
IVF__ICSI / AH	1033
IVF__IVF:ICSI	525
IVF__IVF / AH	424
IVF__ICSI:Unknown	275
IVF__IVF:Unknown	141
DI__ICI	124

```
================================================================================
age_x_specific_proc
```

age_x_specific_proc	count
만18-34세__ICSI	71034
만18-34세__IVF	47647
만35-37세__ICSI	36738
만35-37세__IVF	28440
만38-39세__ICSI	24301
만40-42세__ICSI	22810
만38-39세__IVF	19451
만40-42세__IVF	18688
만18-34세__Unknown	11680
만35-37세__Unknown	8372
만43-44세__ICSI	7002
만43-44세__IVF	6245
만40-42세__Unknown	6059
만38-39세__Unknown	5917
만45-50세__ICSI	3701

```
================================================================================
reason_x_specific_proc
```

reason_x_specific_proc	count
현재 시술용__ICSI	156490
현재 시술용__IVF	113969
현재 시술용__Unknown	36092
missing__IUI	8212
배아 저장용__ICSI	6097
배아 저장용__IVF	3765
기증용, 현재 시술용__ICSI	2777
난자 저장용__IVF	2619
기증용, 현재 시술용__IVF	2194
현재 시술용__ICSI / BLASTOCYST	2152
배아 저장용__ICSI:ICSI	1612
현재 시술용__IVF / BLASTOCYST	1603
현재 시술용__ICSI:ICSI	1421
기증용__IVF	1357
현재 시술용__ICSI:IVF	1063

In [39]:
```python
# 배아·난자 관련 비율 변수 생성
all_data["transfer_per_created_embryo"] = safe_ratio(
    all_data["이식된 배아 수"],
    all_data["총 생성 배아 수"]
)

all_data["stored_per_created_embryo"] = safe_ratio(
    all_data["저장된 배아 수"],
    all_data["총 생성 배아 수"]
)

all_data["thawed_per_stored_embryo"] = safe_ratio(
    all_data["해동된 배아 수"],
    all_data["저장된 배아 수"]
)

all_data["mixed_per_fresh_oocyte"] = safe_ratio(
    all_data["혼합된 난자 수"],
    all_data["수집된 신선 난자 수"]
)

all_data["icsi_oocyte_rate"] = safe_ratio(
    all_data["미세주입된 난자 수"],
    all_data["혼합된 난자 수"]
)

ratio_cols = [
    "transfer_per_created_embryo",
    "stored_per_created_embryo",
    "thawed_per_stored_embryo",
    "mixed_per_fresh_oocyte",
    "icsi_oocyte_rate",
]

display(all_data[ratio_cols].describe())
```

	transfer_per_created_embryo	stored_per_created_embryo	thawed_per_stored_embryo	mixed_per_fresh_oocyte	icsi_oocyte_rate
count	266128.000000	266128.000000	112379.000000	265426.000000	275188.000000
mean	0.367617	0.179962	0.069732	0.862661	0.590923
std	0.318765	0.271368	0.671940	0.213547	0.486579
min	0.000000	0.000000	0.000000	0.000000	0.000000
25%	0.125000	0.000000	0.000000	0.785714	0.000000
50%	0.250000	0.000000	0.000000	1.000000	1.000000
75%	0.500000	0.333333	0.000000	1.000000	1.000000
max	3.000000	7.000000	26.000000	9.000000	1.000000

In [40]:
```python
# train 영역 기준 비율 변수와 target의 관계 확인
train_ratio = all_data.iloc[:len(train_base)].copy()
train_ratio[TARGET] = y.values

ratio_summary = []

for col in ratio_cols:
    temp = train_ratio[[col, TARGET]].copy()
    temp[f"{col}_missing_flag"] = temp[col].isna().astype(int)

    not_missing = temp[temp[col].notna()]
    missing = temp[temp[col].isna()]

    ratio_summary.append({
        "feature": col,
        "missing_count": len(missing),
        "not_missing_count": len(not_missing),
        "missing_success_rate": missing[TARGET].mean(),
        "not_missing_success_rate": not_missing[TARGET].mean(),
        "corr_with_target": temp[[col, TARGET]].corr(numeric_only=True).iloc[0, 1]
    })

ratio_summary_df = pd.DataFrame(ratio_summary)
display(ratio_summary_df)
```

	feature	missing_count	not_missing_count	missing_success_rate	not_missing_success_rate	corr_with_target
0	transfer_per_created_embryo	59640	196711	0.167337	0.285942	-0.092649
1	stored_per_created_embryo	59640	196711	0.167337	0.285942	0.000930
2	thawed_per_stored_embryo	173157	83194	0.218744	0.340782	0.004178
3	mixed_per_fresh_oocyte	60136	196215	0.228815	0.267401	0.071579
4	icsi_oocyte_rate	52941	203410	0.188228	0.276599	-0.013622

02-5. 결과 해석

주요 조합 변수와 비율 변수를 생성하고 분포 및 target과의 관계를 확인하였다.

먼저 조합 변수에서는 `age_x_egg_source`, `treatment_x_specific_proc`, `age_x_specific_proc`, `reason_x_specific_proc` 를 생성하였다.
이 변수들은 단일 변수만으로 설명하기 어려운 상호작용을 모델이 학습할 수 있도록 하기 위한 feature이다.

`age_x_egg_source` 에서는 대부분의 표본이 본인 제공 난자에 집중되어 있으며, 고령 구간에서는 기증 제공 난자 조합도 일정 수 이상 존재한다.
이는 나이 효과가 난자 출처에 따라 달라질 수 있음을 반영하는 변수로 활용할 수 있다.

`treatment_x_specific_proc` 에서는 `IVF__ICSI`, `IVF__IVF`, `IVF__Unknown` 이 가장 큰 비중을 차지한다.
DI에서는 주로 `DI__IUI` 조합이 나타난다.
이는 시술 유형과 세부 시술 유형을 함께 고려해야 IVF/DI의 구조 차이와 세부 시술 방식의 차이를 동시에 반영할 수 있음을 보여준다.

`reason_x_specific_proc` 에서는 `현재 시술용__ICSI`, `현재 시술용__IVF`, `현재 시술용__Unknown` 조합이 가장 많다.
반면 `missing__IUI` 는 DI 계열과 연결된 구조적 결측 조합으로 해석할 수 있다.
따라서 배아 생성 주요 이유의 결측 역시 단순 누락이 아니라 시술 유형과 연결된 정보일 수 있다.

비율 변수에서는 배아와 난자 관련 수량 간의 상대적 관계를 표현하였다.
`transfer_per_created_embryo`, `stored_per_created_embryo`, `thawed_per_stored_embryo`, `mixed_per_fresh_oocyte`, `icsi_oocyte_rate` 를 생성하였다.

비율 변수의 결측 여부 자체도 의미 있는 신호로 나타났다.
예를 들어 `transfer_per_created_embryo` 와 `stored_per_created_embryo` 가 결측인 그룹의 성공률은 약 16.7%, 결측이 아닌 그룹은 약 28.6%로 차이가 크다.

이는 배아 생성 또는 이식 관련 과정이 존재하지 않는 경우 성공률 패턴이 다르다는 것을 의미한다.

`thawed_per_stored_embryo` 는 결측이 아닌 그룹의 성공률이 약 34.1%로, 결측 그룹의 약 21.9%보다 높게 나타났다.
이는 저장 및 해동 배아 관련 정보가 존재하는 경우 임신 성공률이 다르게 나타날 수 있음을 보여준다.

`mixed_per_fresh_oocyte` 역시 결측이 아닌 그룹의 성공률이 약 26.7%, 결측 그룹은 약 22.9%로 차이를 보였다.
`icsi_oocyte_rate` 는 결측이 아닌 그룹의 성공률이 약 27.7%, 결측 그룹은 약 18.8%로 나타났다.

다만 일부 비율 변수는 최댓값이 1을 초과한다.
예를 들어 `transfer_per_created_embryo`, `stored_per_created_embryo`, `thawed_per_stored_embryo`, `mixed_per_fresh_oocyte` 에서 1보다 큰 값이 존재한다.
이는 기록 방식, 분모가 작거나 0에 가까운 경우, 또는 변수 정의 차이에서 발생할 수 있으므로 이후 전처리 단계에서 clipping 또는 이상치 flag 생성을 검토할 필요가 있다.

종합하면, 조합 변수와 비율 변수는 시술 프로세스와 변수 간 상호작용을 반영하는 중요한 feature 후보이다.
이후 모델링에서는 다음 변수를 우선 활용한다.

- `age_x_egg_source`
- `treatment_x_specific_proc`
- `age_x_specific_proc`
- `reason_x_specific_proc`
- `transfer_per_created_embryo`
- `stored_per_created_embryo`
- `thawed_per_stored_embryo`
- `mixed_per_fresh_oocyte`
- `icsi_oocyte_rate`

또한 비율 변수의 결측 여부와 극단값 여부도 별도 flag로 생성할 수 있다.

02-6. 범주형/수치형 변수 정리 및 train/test 재분리

지금까지 train과 test를 결합한 `all_data` 에 동일한 전처리 및 파생변수 생성을 적용하였다.

이제 모델 학습을 위해 다시 train 영역과 test 영역을 분리한다.
또한 모델 입력에 사용할 feature에서 ID 컬럼을 제거하고, 범주형 변수와 수치형 변수를 구분한다.

```
In [41]: # train/test 영역 재분리
X = all_data.iloc[:len(train_base)].copy()
X_test = all_data.iloc[len(train_base):].copy()

print("X:", X.shape)
print("X_test:", X_test.shape)
print("y:", y.shape)
```

```
X: (256351, 114)
X_test: (90067, 114)
y: (256351,)
```

```
In [43]: # ID 컬럼 제거
if ID_COL in X.columns:
    X = X.drop(columns=[ID_COL])

if ID_COL in X_test.columns:
    X_test = X_test.drop(columns=[ID_COL])

print("X after ID drop:", X.shape)
print("X_test after ID drop:", X_test.shape)
```

```
X after ID drop: (256351, 113)
X_test after ID drop: (90067, 113)
```

```
In [44]: # 범주형/수치형 변수 구분
cat_cols = X.select_dtypes(include=["object", "category", "string"]).columns.tolist()
num_cols = [col for col in X.columns if col not in cat_cols]

print("전체 feature 수:", X.shape[1])
print("범주형 변수 수:", len(cat_cols))
print("수치형 변수 수:", len(num_cols))

print("\n범주형 변수 예시:")
print(cat_cols[:20])

print("\n수치형 변수 예시:")
print(num_cols[:20])
```

```
전체 feature 수: 113
범주형 변수 수: 30
수치형 변수 수: 83

범주형 변수 예시:
['시술 시기 코드', '시술 당시 나이', '시술 유형', '특정 시술 유형', '배란 유도 유형', '배아 생성 주요 이유', '총 시술 횟수', '클리닉 내 총 시술 횟수', 'IVF 시술 횟수', 'DI 시술 횟수', '총 임신 횟수', 'IVF 임신 횟수', 'DI 임신 횟수', '총 출산 횟수', 'IVF 출산 횟수', 'DI 출산 횟수', '난자 출처', '정자 출처', '난자 기증자 나이', '정자 기증자 나이']

수치형 변수 예시:
['임신 시도 또는 마지막 임신 경과 연수', '배란 자극 여부', '단일 배아 이식 여부', '착상 전 유전 검사 사용 여부', '착상 전 유전 진단 사용 여부', '남성 주 불임 원인', '남성 부 불임 원인', '여성 주 불임 원인', '여성 부 불임 원인', '부부 주 불임 원인', '부부 부 불임 원인', '불명확 불임 원인', '불임 원인 - 난관 질환', '불임 원인 - 남성 요인', '불임 원인 - 배란 장애', '불임 원인 - 여성 요인', '불임
원인 - 자궁경부 문제', '불임 원인 - 자궁내막증', '불임 원인 - 정자 농도', '불임 원인 - 정자 면역학적 요인']
```

```
In [45]: # 범주형/수치형 변수 구분
cat_cols = X.select_dtypes(include=["object", "category", "string"]).columns.tolist()
num_cols = [col for col in X.columns if col not in cat_cols]

print("전체 feature 수:", X.shape[1])
print("범주형 변수 수:", len(cat_cols))
print("수치형 변수 수:", len(num_cols))

print("\n범주형 변수 예시:")
print(cat_cols[:20])

print("\n수치형 변수 예시:")
print(num_cols[:20])
```

```
전체 feature 수: 113
범주형 변수 수: 30
수치형 변수 수: 83

범주형 변수 예시:
['시술 시기 코드', '시술 당시 나이', '시술 유형', '특정 시술 유형', '배란 유도 유형', '배아 생성 주요 이유', '총 시술 횟수', '클리닉 내 총 시술 횟수', 'IVF 시술 횟수', 'DI 시술 횟수', '총 임신 횟수', 'IVF 임신 횟수', 'DI 임신 횟수', '총 출산 횟수', 'IVF 출산 횟수', 'DI 출산 횟수', '난자 출처', '정자 출처', '난자 기증자 나이', '정자 기증자 나이']

수치형 변수 예시:
['임신 시도 또는 마지막 임신 경과 연수', '배란 자극 여부', '단일 배아 이식 여부', '착상 전 유전 검사 사용 여부', '착상 전 유전 진단 사용 여부', '남성 주 불임 원인', '남성 부 불임 원인', '여성 주 불임 원인', '여성 부 불임 원인', '부부 주 불임 원인', '부부 부 불임 원인', '불명확 불임 원인', '불임 원인 - 난관 질환', '불임 원인 - 남성 요인', '불임 원인 - 배란 장애', '불임 원인 - 여성 요인', '불임
원인 - 자궁경부 문제', '불임 원인 - 자궁내막증', '불임 원인 - 정자 농도', '불임 원인 - 정자 면역학적 요인']
```

02-6. 결과 해석

전처리 및 Feature Engineering을 적용한 결과, 최종 feature 수는 113개로 구성되었다.
기존 원본 feature 수가 67개였던 점을 고려하면, EDA 기반 파생변수를 통해 약 46개의 feature가 추가되었다.

최종 feature 중 범주형 변수는 30개, 수치형 변수는 83개로 분리되었다.
범주형 변수에는 시술 시기 코드, 시술 당시 나이, 시술 유형, 특정 시술 유형, 배란 유도 유형, 배아 생성 주요 이유, 시술 횟수 관련 변수, 난자/정자 출처 등이 포함된다.

수치형 변수에는 배란 자극 여부, 단일 배아 이식 여부, 불임 원인 관련 이진 변수, 배아·난자 수량 변수, 경과일 변수, 그리고 새로 생성한 flag 및 비율 변수가 포함된다.

범주형 변수는 CatBoost에서 직접 처리할 수 있도록 문자열 형태로 변환하고, 결측값은 `missing` 범주로 처리하였다.
수치형 변수는 숫자형으로 변환하되, 결측값은 우선 NaN으로 유지하였다.

이번 전처리의 핵심은 단순히 변수 개수를 늘리는 것이 아니라, EDA에서 확인한 다음 정보를 모델이 학습할 수 있도록 구조화했다는 점이다.

- 시술 유형별 구조적 결측
- 임상 지식 기반 FER/ICSI/자연주기 유추 flag
- 나이, 난자 수, 배아 수의 구간 패턴
- 나이와 난자 출처의 조합
- 시술 유형과 특정 시술 유형의 조합
- 배아·난자 관련 비율 정보

이제 모델링 단계에서는 이 feature set을 활용하여 Baseline 모델과 CatBoost 모델을 학습하고, ROC-AUC 기준으로 성능을 비교한다.

03. 모델링

모델링 단계에서는 Baseline 모델부터 시작해 CatBoost, LightGBM, XGBoost 등 트리 기반 모델을 비교하고, K-Fold OOF 기반으로 성능을 검증한다.

04. 평가

평가는 ROC-AUC를 핵심 지표로 사용한다. 보조적으로 LogLoss, Accuracy, Precision, Recall, F1-score를 함께 확인한다.

05. 제출 및 리더보드 확인

최종 모델 또는 앙상블 모델로 test 데이터의 임신 성공 확률을 예측하고, 제출 형식에 맞는 CSV 파일을 생성한다.